


Présentation du Support Méthodologique P3

#User Story : P3 – Requêtez une base de données avec SQL

En tant que [Data Analyst], je [suis] responsable de la qualité et de l'exécution des analyses en utilisant une méthode de bout en bout en 10 étapes.

Je veux [explorer] une base de données et y [extraire] des informations précises utiles [afin d'] apporter une analyse approfondie des données



1 – Analyse des Besoins

Collecte d'Informations : Comprendre les exigences des utilisateurs et des parties prenantes en analysant l'existant.

Identifiez les Données Nécessaires : Déterminer quelles données doivent être stockées au moyen d'un dictionnaire des données.

Le dictionnaire des données : j'ai observé les colonnes des fichiers, recherché les typologies de données Contrat et Région puis j'ai ajouté les contraintes nécessaires.

Combien existe-il de contrats sur les résidences principales ?


- Quels sont les 5 contrats qui ont les surfaces les plus élevées ?
- Quel est le prix moyen de la cotisation mensuelle ? Etc ...

	Nom des colonnes	Type de données	Taille	Clé	Description
CONTRAT.CSV	Contrat_ID	INT	6	Clé primaire	Id unique pour les contrats
	No_voie	INT	4		Numéro dans la voie pour l'adresse du logement assuré
	B_T_Q	CHAR	1		Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
	Type_de_voie	VARCHAR	4		Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route), ...
	Voie	VARCHAR	4		Libellé de la voie pour l'adresse du logement assuré
	Code_dep_code_commune	VARCHAR	5	Clé secondaire	Concaténation du code département et code commune pour avoir une clé unique
	Code_postal	INT	5		Code postal pour l'adresse du logement assuré
	Surface	INT	3		Nombre en Mètre carré de surface habitable (o)
	Type_local	VARCHAR	11		Liste prédéfinie: "Appartement" ou "Maison"
	Occupation	VARCHAR	12		Liste prédéfinie: "Locataire" ou "Propriétaire"
	Type_contrat	VARCHAR	20		Liste prédéfinie: "Résidence principale", "Résidence secondaire", "Mise en location"
	Formule	VARCHAR	9		Liste prédéfinie: "Integral" ou "Classique"
	Valeur_declaree_biens	VARCHAR	11		Liste prédéfinie de 4 items: "0-25000", "25000-50000", "50000+", "100000+"
	Prix_cotisation_mensuel	INT	3		Nombre de 1 à 3 chiffres
REGION.CSV	Code_dep_code_commune	VARCHAR	5	Clé primaire	Concaténation du code département et code commune pour avoir une clé unique
	reg_code	INT	2		Code département y compris Collectivités d'outre-mer (0)
	reg_nom	VARCHAR	30		Liste prédéfinie de 20 noms de régions françaises
	aca_nom	VARCHAR	50		Liste prédéfinie de 37 noms de chef-lieu 1 pour chaque région reg_nom
	dep_nom	VARCHAR	50		Liste prédéfinie de 113 noms de département
	com_nom_maj_court	VARCHAR	30		Liste de nom court de commune mis à jour
	dep_code	INT	3		Numéro du département
	dep_nom_num	VARCHAR	50		Concaténation du dep_nom avec le "(" + code département + ")"

2 - Conception du Modèle Conceptuel (MCD)



Identification des Entités : j'ai créé un MCD reprenant l'intégralité de l'ensemble des données des deux fichiers csv sous forme d'entités (Tableaux) et d'attributs (colonnes).

Détermination des Relations : J'ai identifié ensuite comment les entités interagissent entre elles au moyen de clés primaires comme identifiant unique et de clés étrangères pour les relations dans un AGL(SQL Power Architect)qui génère du Code SQL.




3 - Conception du Modèle Logique (MLD)

- **Modèle Relationnel** : j'ai transformé le modèle conceptuel en un modèle logique compatible 3NF et relationnel et j'ai généré un script SQL pour le SGBD futur choisi.
- **Mon schéma relationnel de base de données fait en sorte d'intégrer l'ensemble des données des deux fichiers Contrat.csv et Region.csv.**
- **Définition des Clés** : J'ai déterminé les clés primaires comme contrainte d'unicité et les clés étrangères pour garantir l'Intégrité Référentielle.




4 - Conception du Modèle Physique(MPD)

- **Caractéristiques Techniques** : J'ai créé une base de données **MyBaseSQL** pour le SGBD MySQL dans **Dbeaver** pour déterminer la structure physique des **2 tables Contrat et Region**, leurs **attributs** et leurs **types** de données.
- **Optimisation des Performances** : J'ai considéré comment les données seront **indexées** pour améliorer les performances des requêtes par **la nécessité de recourir aux clés primaires et étrangères dans le SGBDR** (intégrité référentielle).



5 - Implémentation

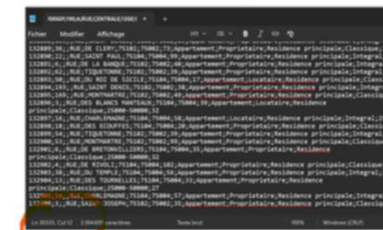

- **Création des Tables** : j'ai utilisé le script SQL généré dans Power Architect directement depuis la base de données **MyBaseSQL** dans Dbeaver pour créer les tables .
- **Puis j'ai dû recréer des clés primaires et étrangères manuellement**: pour définir les relations proprement .
- **Configuration du Système** : j'ai configuré une sauvegarde de mon SGBDR et les paramètres de sécurité de la base sur mon Workspace.



6 - Chargement des Données

Migration des Données : j'ai importé les données existantes à partir du navigateur et des fichiers csv.

Validation : J'ai pu vérifier que les données ont été correctement chargées.(voir doc technique pour la table Region).





Analyse des données Contrat TCD1

Nombre de Contrat_ID	Occupation		
Type_contrat	Locataire	Propriétaire	Total général
Mise en location		2331	2331
Residence principale	8997	16623	25620
Residence secondaire		2384	2384
Total général	8997	21338	30335

OK

- La table Contrat compte 30335 lignes chargées comme en contenait le fichier csv OK



Analyse des données Région TCD2




reg_nom	Nombre de aca_nom
Grand Est	5596
Nouvelle-Aquitaine	4693
Occitanie	4627
Auvergne-Rhône-Alpes	4380
Bourgogne-Franche-Comté	4018
Hauts-de-France	3952
Normandie	3385
Centre-Val de Loire	1892
Ile-de-France	1837
Pays de la Loire	1574
Bretagne	1320
Provence-Alpes-Côte d'Azur	1032
Corse	366
Collectivités d'outre-mer	92
Mayotte	34
Guadeloupe	34
Martinique	34
Guyane	26
La Réunion	24
Total général	38916

- La table Region compte bien 38 916 lignes comme le fichier csv d'entrée OK

7 – Tests et Validation

Tests de fonctionnalités : J'ai pu vérifier que la base de données fonctionne comme prévu (insertion, mise à jour, requêtes, etc.) en utilisant les commandes : SELECT , INSERT et UPDATE

Tests d'intégrité : J'ai vérifié que si une entrée de la table référencée est supprimée ou modifiée, les entrées qui y font référence doivent également être mises à jour ou supprimées pour éviter les incohérences



8 - Documentation



- **Documentation technique:** j'ai créé une documentation technique sur la structure de la base de données, les relations et les tests d'intégrités référentielles.

- **Document Liste de Requêtes SQL utilisées:** j'ai fourni la liste des requêtes demandées documentées des résultats et des tableaux générés pour une première version afin d'afficher un Tableau de Bord d'insights(indicateurs des chiffres clés).



9 – Mise en production

- **Déploiement de la Base de Données :** Mettre en service la base de données pour un usage réel relève d'une collaboration avec le DATA ingénieur.
- **Surveillance Continue :** De même que mettre en place des outils pour surveiller les performances et réaliser des sauvegardes régulières.



Avez-vous des questions ?

10 – Maintenance et évolution

- **Gestion des Performances :**
Optimiser régulièrement pour améliorer les performances et la sécurité relèvent des compétences du Data Ingénieur. Les clés permettent cependant d'articuler des requêtes plus efficaces, permettant de récupérer facilement les données liées de plusieurs tables.
- **Mises à Jour :** Les clés que j'ai créées aideront à gérer les opérations de mise à jour et de suppression de manière plus efficace, en s'assurant que les bonnes lignes ont bien été affectées. Elles minimisent les risques d'erreurs humaines lors de la gestion des données. Elles permettent aux analystes de créer des rapports précis et d'extraire des insights pertinents à partir des données.

