



Analyse de l'évolution de profils sociodémographiques des étudiants DATA d' OpenClassrooms avec DBT

Ferial ZAMOUN -GRETA – Parcours DATA ANALYST

13 mars 2026



Contexte

Dans un marché du travail en constante évolution, OpenClassrooms s'engage à offrir des formations DATA pertinentes et accessibles. Comprendre en profondeur qui sont les étudiants DATA OC est essentiel pour mieux les accompagner, optimiser leur parcours d'apprentissage et s'assurer que les offres répondent aux réalités et aux besoins d'une audience diversifiée.



Identifier les profils

Analyser les données sociodémographiques (genre, âge, situation géographique) pour dresser un portrait précis de nos étudiants DATA.



Affiner les stratégies

Développer des campagnes de recrutement et de communication plus ciblées et inclusives, atteignant efficacement nos futurs talents.



Optimiser l'offre

Adapter les contenus pédagogiques, les modalités d'accompagnement et les parcours de carrière en fonction des caractéristiques de nos apprenants.



Promouvoir l'équité

Renforcer notre engagement envers la diversité et l'inclusion en identifiant les écarts et en proposant des solutions équitables.



Objectifs du projet



Objectiver les tendances

Analyser la répartition par âge, genre et région de 2022 à 2025 pour alimenter les réflexions stratégiques sur l'accessibilité et l'égalité des chances.



Transformer les données

Préparer, fiabiliser et enrichir les données issues des bases internes en les associant aux données publiques de l'INSEE grâce à un pipeline de données et un workflow DBT



Respecter le RGPD

Traiter les données en conformité stricte avec le règlement général sur la protection des données.





Mesurer l'évolution


Construire des indicateurs statistiques pour suivre l'évolution du profil sociodémographique des étudiants.

Méthodologie & Pipeline DBT

Notre pipeline de données orchestre l'intégration de sources multiples vers des tables analytiques prêtes à l'emploi. La plateforme combine Snowflake pour le stockage, dbt Cloud (version 1.11.7) pour les transformations, et Python pour la visualisation des graphiques.



Architecture du Pipeline



**Données
brutes**

Ingest Snowflake

Staging dbt

Nettoyage initial

**Intermédiaire
dbt**

Jointures
complexes

Marts dbt

Tables finales

Tests & Export

Tests automatisés+
CSV

Pourquoi choisir DBT ?

Qualité

Tests intégrés pour des données fiables.

Gouvernance

Documentation automatique et lignage des données.

Productivité

Développement collaboratif et réutilisable.

Collecte des Données



Sources Primaires

DATASET+--+MAJ+--+P8+--+1040+--+DA+--+DATA.csv: Données de plateforme OpenClassrooms (2022-2025)

Estimation_popu_2025_dpt_sexe_classe_age.xls : données démographiques départementales INSEE avec tranches d'âge, genre et années

fr-esr-referentiel-geographique.csv : référentiel géographique officiel établissant la correspondance département-région

L'extraction Python (`extract_insee_population.py`) convertit les fichiers sources de données publiques de l'INSEE en format CSV, puis enrichit les données par la correspondance département-région.

Modèles de Staging dbt

stg_étudiants

Nettoyage et harmonisation des données étudiants : normalisation des régions (DOM → DROM), gestion des accents et tirets, standardisation des tranches d'âge (ex: "30 à 34 ans" → "30-34 ans"), agrégation "60 ans ou plus"

stg_insee_population


Dépivotage des données INSEE : transformation du format large (colonnes par genre/âge) en format long (une ligne par année/région/âge/genre), harmonisation des tranches d'âge pour alignement

Modèle Intermédiaire

int_etudiants_insee_joined

Jointure **FULL OUTER JOIN** centralisant la logique de rapprochement sur des dimensions communes (année, région, genre, classe d'âge INSEE) avant exposition en marts.

- Harmonisation des tranches d'âge : mapping 20-39 ans, 40-59 ans, 60+ avec format standardisé
- Gestion des valeurs manquantes GENDER : conservation des valeurs "Non renseigné"
- Harmonisation régionale vers libellé canonique unique (ex: 'Auvergne-Rhône-Alpes')
- Tests : NOT NULL et ACCEPTED_VALUE appliqués automatiquement



Tables Finales

01

fct_profil_sociodem

Table de fait : Profil sociodémographique des étudiants
(grain détaillé)

03

fct_summary_analysis

Marts de synthèse : comparaison structure par genre entre
étudiants et INSEE (grain : année, région, genre)

02

fct_insee_par_region_age

Table d'analyse : agrégation INSEE par région, année, classe
d'âge et genre

04

fct_export_unifie

Marts orienté export CSV pour Tables finales et
reconstitution des indicateurs métiers

Contrôles de Qualité

Tests Automatisés dbt


- Unicité du grain (clé primaire composite)
- Cohérence des jointures (test valeurs non nulles)
- Acceptation de valeurs (domaines valides alias accepted value)
- Normalisation régionale (libellés canoniques)
- Contrôle de cohérence des colonnes clés (YEAR, REGION, GENDER, AGE_GROUP)

Traçabilité et Documentation

- Documentation automatique et lignage des données
- Chaque modèle est documenté et versionné dans des fichiers YAML (sources.yml et schema.yml)
- DAG de traçabilité : visibilité des dépendances métiers

industrialisation: Job automatisé dans DBT

📄 Export CSV : manuel depuis SN sur la table finale dédiée : `fct_export_unifie`



Conformité RGPD et protection des données

01

Aucune donnée nominative

Les livrables ne contiennent aucune information personnelle identifiable.

02

Données agrégées

Traitements exclusivement en données agrégées pour garantir l'anonymization. Utilisation d'identifiants Numériques.

03

Minimisation des données

Collecte limitée aux seules données nécessaires à l'analyse finale

04

Finalité analytique

Utilisation strictement réservée à des fins d'analyse descriptive

Le résultat est une analyse descriptive entièrement conforme à l'esprit et aux exigences du RGPD, garantissant la protection de la vie privée des apprenants.



Une dynamique de déclin marquée entre 2022 et 2024

1 696

Étudiants en 2022

Volume de départ avant la période de déclin

-44%

Baisse en deux ans

Chute spectaculaire du nombre d'apprenants

850


Étudiants en 2024

Quasiment divisé par deux

951

Rebond en 2025

Amorce de reprise, niveau pas retrouvé



Le volume d'apprenants a chuté de -44% entre 2022 et 2024, avant un rebond partiel en 2025. Cette dynamique de déclin puis de rebond constitue le contexte démographique de fond de toute l'analyse qui suit.

Une population majoritairement masculine


22,7% de femmes

Les hommes dominent structurellement la population OpenClassrooms, avec une part féminine chroniquement minoritaire sur toute la période 2022-2025.

26,8% de non renseigné

Une fraction non négligeable de données manquantes limite la précision de certains calculs et appelle à une amélioration de la collecte.

Repartition des etudiants OC par genre (%) - avec Non renseigné



Une fracture de genre massive et persistante


Femmes OC

≈ 31%

Femmes INSEE

≈ 52%

-20 points



Chiffre clé de l'analyse : Les femmes sont sous-représentées de ~20 points dans OC par rapport à leur poids dans la population INSEE, symétrique à +20 points pour les hommes. Une fracture de genre massive, constante, et mesurable.


Une structure d'âge globalement stable, avec un noyau centré sur les 25–34 ans

Tranches dominantes

- **30–34 ans** : baisse notable des 30–34 ans entre 2023 et 2024, puis légère remontée
- **25–29 ans** : hausse visible des 25–29 ans jusqu'en 2024, puis stabilisation.
- **20–24 ans** : augmentation continue des 20–24 ans


Peu de croisements

- On observe un **croisement entre 25–29 et 30–34 autour de 2024** ce qui représente une inversion partielle de hiérarchie et un rajeunissement partiel (pas massif)
- Stagnation ou érosion légère des tranches supérieures



Malgré la baisse globale des volumes, la composition démographique évolue à la marge. Le socle central des 25–34 ans demeure structurant sur l'ensemble de la période.

Une sur-représentation significative et structurelle de l'Île-de-France



Île-de-France

+33.51%

Sur-représentation massive au-delà de tout ce qu'on pourrait attribuer à sa taille démographique

Régions

-0.52%

10 autres régions toutes sous-représentées, de -0,52 à -2,73 points, sous-representation de moitié moins pour la structure d'ensemble des regions.

Cela suggère :

- un effet d'écosystème (formation, emploi, numérique),
- une attractivité spécifique du territoire lié au bassin d'emploi
- un déséquilibre d'accès selon les régions



Diagnostic Inégalités : Vers une Action Concertée

OpenClassrooms concentre massivement ses recrutements auprès d'actifs urbains, masculins et résidant en Île-de-France. L'analyse des données sur 4 ans révèle une persistance marquée de ces écarts démographiques, sans rééquilibrage spontané observé.

Le dispositif data récemment déployé permet désormais de quantifier ces disparités avec fiabilité et répétabilité, offrant une base solide pour orienter des actions concrètes visant à améliorer l'équité d'accès aux parcours de formation.



Ciblage régional

Lancer des opérations spécifiques hors Île-de-France avec des messages adaptés aux spécificités locales



Attractivité féminine

Renforcer les témoignages femmes, clarifier les parcours de retour à l'emploi, et faciliter l'équilibre formation-vie personnelle



Ancrage territorial

Établir des partenariats locaux et régler les obstacles contextuels

Prochaines étapes : Intégrer des variables socio-économiques additionnelles (niveau d'éducation, secteur d'activité) et tester des segmentations plus fines pour identifier les leviers d'action les plus efficaces.

