

Projet P11 : Produisez une étude de marché en Python

ÉTUDE DE MARCHÉ — EXPORT

La Poule qui Chante

Expansion à l'internationale pour l'exportation de **poulets biologiques** — Analyse multivariée, segmentation et recommandations stratégiques pour identifier les marchés cibles à fort potentiel.





Contexte du Projet

Objectif

Identifier des pays cibles pour exporter du **poulet biologique** depuis la France vers des marchés internationaux à fort potentiel de croissance et de différenciation.

Enjeux stratégiques

Trouver des marchés **favorables, comparables et robustes** pour une expansion durable, en s'appuyant sur une analyse rigoureuse des données mondiales issues de sources institutionnelles reconnues.

Approche analytique

Analyse multivariée et segmentation des pays à partir de **données internationales** : disponibilité alimentaire, production et importations de volaille, indicateurs économiques, stabilité politique, accessibilité logistique, etc.

Objectifs de l'Étude

Analyse P.E.S.T.E.L



PESTEL				
N°	Hypothèse business	Indicateur(s) utilisés	Limite principale	Action corrective proposée
Politique	Un environnement stable facilite l'entrée et la continuité commerciale	'political_stability'	Proxy moins, ne capture pas les chocs exogènes (élections, conflits)	Ajouter un indicateur exogénéral (instabilité récente, élections, conflits)
Économique	Les pays riches et importateurs sont plus attractifs pour un produit premium	'gdp_per_capita_usd', 'poultry_import_usd_tonnes', 'poultry_import_usd_kcal', 'import_usd_per_capita_kg'	Surpondre potentiellement les grands marchés en volume	Tester un scénario plus intensifié (par capita) et comparer le top 10%
Social	Les dynamiques de demande et de population conditionnent le potentiel commercial	'population', 'population_growth_rate_usd', 'kcal_per_capita_day'	Certaines mesures sont des photos annuelles et pas des tendances longues	Passer en panel pays-années et ajouter des tendances glissantes
Technologique	La capacité logistique influence la faisabilité opérationnelle de l'export	'logistics_score' (proxy UNICEF), 'distance_proximate_logistique'	Proxy indirect, qualité hétérogène selon zones et milieux	Corréler avec coût transport réel et délai moyen par corridor
Environnemental	L'efficacité de chaîne et les risques sanitaires influencent la soutenabilité du marché	'losses_to_production_poultry', 'aules_events_recent_2y_count', 'aules_events_2017_count'	Les zéros peuvent masquer l'absence d'événement et manque de déclaration	Distinguer 'structural_pain' et 'missing_source' dans les exports
Réglementaire	Un cadre réglementaire adéquat structure le risque d'entrée sur le marché	'fodex_text_recent_10y_count', 'fodex_text_active_count', 'fodex_text_diversity_score'	(Proxys textuels, ne mesurent pas directement la sécurité juridique)	Ajouter une revue qualitative ciblée sur les 10 pays prioritaires

Quatre ambitions analytiques structurent cette étude, depuis la compréhension des données jusqu'à la recommandation opérationnelle.

① Comprendre les corrélations

Identifier les relations entre variables clés : taille du marché, dépendance aux importations, accessibilité économique et logistique.

② Réduire la dimension

Optimiser les modèles par ACP afin de passer de 11 variables brutes à un espace synthétique non redondant, propice au clustering.

③ Segmenter les pays

Regrouper les 138 pays en clusters homogènes selon leur profil marché afin de prioriser les cibles d'exportation de manière rigoureuse.

④ Recommander un Top 5

Identifier le pays prioritaire et un classement des cinq marchés les plus prometteurs pour le lancement commercial international.

cat	variable	description	type	unité	commentaire
0	disponibilite_volaille_kg_hab_an	disponibilité volaille kg hab an	float	kg/hab/an	disponibilité volaille kg hab an
1	log_population_2017	log population 2017	float	log	log population 2017
2	part_importations_poulet	part importations poulet	float	%	part importations poulet
3	signal_maturite_bio_import	signal maturite bio import	float	signal	signal maturite bio import
4	log_production_poulet	log production poulet	float	log	log production poulet
5	ease_business_score	ease business score	float	score	ease business score
6	political_stability	political stability	float	score	political stability
7	log_gdp_per_capita	log gdp per capita	float	log	log gdp per capita
8	log_distance_france	log distance france	float	log	log distance france
9	langue_officielle_commune_france	langue officielle commune france	float	score	langue officielle commune france
10	log_evenements_sanitaires	log evenements sanitaires	float	log	log evenements sanitaires



Marché



Bio



Distance



Risque



Institutionnel

Partie 1 : Sélection des Variables Actives Retenues pour l'ACP

Contrôle du centrage et de la mise à l'échelle robuste — **11 variables actives** standardisées avec RobustScaler.

Critères de sélection

- **Pertinence métier** : Attractivité et contraintes d'un marché export.
- **Couverture suffisante** : Données disponibles pour l'ensemble des pays.
- **Non-redondance** : $|\text{corrélation Pearson}| < 0.80$ entre toutes les paires. Heatmap des corrélations
- **Lisibilité PESTEL** : Alignement Politique, Économique, Social, Technologique, Environnemental, Légal.
- **Retrait de la France** *comme pays importateur pour éviter l'auto-referencement.*

Contrôle du centrage et de la mise à l'échelle robuste

	variable_technique	variable_fr	centre_mediane	ec/1/e_iqr
0	disponibilite_volaille_kg_hab_an	disponibilite volaille kg hab an	16.782500	22.145500
1	log_population_2017	log population 2017	9.155852	2.426873
2	part_importations_poulet	part importations poulet	0.132724	0.515290
3	signal_maturite_bio_import	signal maturite bio import	-0.324978	0.230011
4	log_production_poulet	log production poulet	11.374008	2.752358
5	ease_business_score	ease business score	61.728605	19.335228
6	political_stability	political stability	-0.020000	1.285000
7	log_gdp_per_capita	log gdp per capita	9.514355	1.748158
8	log_distance_france	log distance france	8.623854	0.990836
9	langue_officielle_commune_france	langue officielle commune france	0.000000	1.000000
10	log_evenements_sanitaires	log evenements sanitaires	0.000000	0.693147

Conclusion sur les variables retenues pour l'ACP

À ce stade, les variables actives de l'ACP sont définies et préparées. Elles couvrent les dimensions nécessaires à l'étude de marché : taille et dynamique de la demande, dépendance aux importations, accessibilité économique, contraintes logistiques, stabilité du pays et potentiel commercial.

La nouveauté importante est que ces variables ne sont plus analysées séparément dans leurs unités d'origine. Elles sont désormais rendues comparables par la standardisation, ce qui permet d'étudier leurs relations entre elles et leur contribution commune aux axes de l'ACP.

Partie 2 : ACP & Réduction de Dimension

Objectifs de l'ACP – Analyse par Composante Principale

Réduire la complexité analytique en passant de **11 variables brutes** à **3 composantes principales synthétiques** (PC1, PC2, PC3), sans perdre l'essentiel de l'information. La standardisation robuste via *RobustScaler* limite l'influence des valeurs atypiques sur la structure factorielle.

89.9%

Variance cumulée

Expliquée par PC1 + PC2 + PC3 conjointement.

0.422

Orientation PC1



PC1 • 40%

Signal bio/import premium —
dominé par la maturité import
bio.

PC2 • 14.3%


Risque sanitaire et intensité
productive.

PC3 • 5.7%



Taille productive, stabilité et dépendance aux importations.

Lecture Métier

Corrélation PC1 / score métier. Orientation retenue : 1.



Partie2 : Résultats ACP : Variance Expliquée et Signal de Kaiser




Éboulis de variance expliquée

La courbe cumulée franchit le seuil des **80 %** dès PC3, confirmant que trois composantes suffisent à capturer l'essentiel de la structure multivariée du jeu de données. Ce résultat valide le choix de réduire l'espace analytique à 3 dimensions.

Signal Kaiser (valeur propre > 1)

Seules **PC1, PC2 et PC3** dépassent le seuil de Kaiser. Ce critère classique confirme de façon indépendante la pertinence statistique des trois axes retenus pour alimenter le clustering non supervisé.

Partie2 : Résultats ACP : Cercle des Corrélations PC1 / PC2



PC1 comme score exploratoire synthétique

Le cercle des corrélations confirme la domination de `signal_maturite_bio_import` sur PC1 avec **69.8 % de la variance**, bien isolé des autres variables — ce qui en fait un axe très lisible et interprétable.

PC2 (14.3 %) capture la dimension sanitaire et productive, notamment `log_evenements_sanitaires` au sommet du cercle, orthogonal à PC1.

- i** PC1 à PC3 servent conjointement à construire l'espace de clustering. PC1 seul n'est utilisé qu'à titre exploratoire d'interprétation — la segmentation repose sur les trois axes.


Partie2 : Projection des Pays dans le Plan Factoriel PC1/PC2 et PC1/ PC3

Chaque point représente un pays projeté par l'ACP dans le plan PC1 /PC2 et PC1/ PC3. La position dépend uniquement des coordonnées factorielles issues des variables actives.



Lecture du plan PC1/PC2


Les pays situés à droite du graphique ont un profil plus marqué sur le **signal de maturité bio/import**. Les pays situés plus haut sont davantage **associés au contexte sanitaire et productif**. Les pays proches du centre sont moins différenciés dans ce premier plan.



Utilité complémentaire de PC3

PC3 (5.7 %) distingue les pays **proches sur PC1/PC2 mais différents** en termes de taille productive, stabilité et dépendance aux importations — **essentiel pour affiner la segmentation en clusters opérationnels**.

Partie2 : Clustering Non Supervisé : Méthodologie et cycle itératif



Standardisation

ACP

KMeans

CAH

Pourquoi travailler sur les composantes ACP ?

Appliquer KMeans directement sur les variables brutes risque d'introduire des **redondances et des distorsions de distance**. Les composantes ACP forment un espace synthétique, orthogonal et non redondant, qui stabilise les calculs de proximité entre pays.

Double validation : KMeans + CAH

La **CAH** (Classification Ascendante Hiérarchique) permet de visualiser la structure naturelle des groupes via un dendrogramme, avant que **KMeans** ne transforme cette structure en affectation opérationnelle stable pour chaque pays.

Partie2 : Dendrogramme CAH et Validation KMeans



CAH — Lecture visuelle

Il est plus logique de commencer par la Classification Ascendante Hiérarchique : elle donne une **première lecture visuelle** de la structure des distances entre pays, sans imposer immédiatement un nombre de groupes. Le dendrogramme révèle les ruptures naturelles dans la hiérarchie des distances.

KMeans — Affectation opérationnelle

On utilise ensuite KMeans pour produire une segmentation opérationnelle avec un nombre de clusters choisi à partir de **diagnostics quantitatifs** : inertie, silhouette et taille minimale des groupes. Cette approche séquentielle garantit une segmentation à la fois interprétable et robuste statistiquement.

Partie2 : KMeans : De la CAH à la Segmentation Opérationnelle

Rôle de KMeans après la CAH

KMeans est appliqué *après* la CAH pour transformer la structure hiérarchique observée dans le dendrogramme en une **segmentation opérationnelle** : chaque pays reçoit une affectation stable et exploitable.

L'objectif n'est plus seulement de visualiser des proximités, mais de **délimiter des groupes homogènes** directement utilisables pour la recommandation marché.

Application sur les composantes ACP

KMeans est appliqué sur les **coordonnées ACP** (PC1, PC2, PC3) et non sur les variables brutes. Cette approche garantit :

- L'absence de redondance dans l'espace de clustering.
- La stabilité des distances entre pays dans un espace euclidien normalisé.
- Une meilleure séparabilité des clusters, mesurée par le score de silhouette.

❏ Étape 3 du pipeline — regrouper les pays sur les composantes ACP retenues.

Partie2 : Critères de sélection du nombre de clusters par Kmeans

Trois diagnostics complémentaires ont guidé le choix du nombre optimal de clusters, garantissant une segmentation à la fois compacte, bien séparée et représentative.

1

Inertie

Mesure la **compacité interne** des groupes via la somme des distances au carré. Elle diminue naturellement avec k — l'objectif est d'éviter la sur-segmentation.

2

Score de silhouette

Mesure la **séparation entre clusters**.
Valeur maximale atteinte : **0.70 pour $k=2$** , indiquant une bonne distinction entre les groupes.


3

Taille minimale

Chaque cluster doit contenir ≥ 5 **pays** ou représenter $\geq 3\%$ **du total** pour garantir la pertinence opérationnelle de la segmentation.

✅ **Résultat :** ✅ **2 clusters** retenus — Cluster 1 : pays à signal bio/import premium fort (ex : Suisse, Belgique). Cluster 2 : pays moins marqués sur PC1, profil plus prudent.

Partie2 : KMeans : inertie (méthode du coude) KMEANS et Score de silhouette



Baisse normale du nombre de clusters

Plus on crée de clusters, plus chaque pays peut être rapproché d'un centroïde. La valeur la plus basse n'est donc pas automatiquement la meilleure solution, car elle peut correspondre à une segmentation trop découpée.


Une silhouette autour de 0,70 pour k=2 indique une séparation élevée entre les deux groupes

2 clusters est le meilleur compromis. Ce choix conserve une silhouette élevée, évite les micro-clusters, garde deux groupes exploitables et reste cohérent avec la séparation macro observée dans la CAH. Les solutions avec plus de clusters réduisent bien l'inertie, mais elles le font au prix d'une segmentation trop fragmentée.

Exploitabilité métier : taille minimale des Clusters

Est-ce que chaque cluster contient assez de pays pour représenter une vraie famille de marchés, ou est-ce qu'on a seulement isolé quelques cas atypiques ?

Partie2 : KMeans : Projection ACP des Clusters — Pays Prioritaires PC1 / PC2



Taille minimale exigée par cluster : 5 pays

Nombre de clusters KMeans retenu : 2

42 pays du segment priorité immédiate répartis dans 2 clusters

16 pays prioritaires les plus éloignés sur l'axe PC1/PC2 : dont 9 intéressants+ 1 atypique (Allemagne) + 1 Outlier (INDE)

Choix du nombre optimal de Clusters— On retient le k exploitable qui maximise la silhouette ; sinon, on utilise la silhouette seule.


Cluster 2 — Marchés prioritaires

Le cluster **orange** regroupe les pays avec un **signal bio/import premium élevé** (PC1 fort). On y retrouve les cibles prioritaires : **Autriche, Suède, Finlande, Italie, Estonie, Lettonie, Danemark, Belgique, Allemagne** — tous bien séparés de la masse.

Cluster 1 — Marchés à surveiller

Le cluster **bleu** regroupe la majorité des pays, caractérisés par un signal bio faible ou négatif. Ces marchés présentent des **barrières logistiques, économiques ou réglementaires plus élevées pour une entrée à court terme du poulet biologique français**.

Partie2 : KMeans : Projection ACP des Clusters — Pays Prioritaires PC1-PC3



Nombre de clusters KMeans retenu : 2

Taille minimale exigée par cluster : 5 pays

12 pays marchés prioritaires les plus éloignés sur l'axe PC1/PC3

+ 1 pays marché à surveiller

☐ Certains pays bien classés en PC1/PC2 présentent des différences représentatives en seconde analyse avec le reste du groupe. **PC1/PC3** pour affiner la décision finale.

Cluster 2 — Marchés prioritaires

Le cluster **orange** regroupe toujours les pays avec un **signal bio/import premium élevé** (PC1 fort). Mais on affine l'analyse par la dimension taille productive, stabilité et dépendance à l'import pour différencier les pays proches lors de la sélection finale

Cluster 1 — Marchés à surveiller

Le cluster **bleu** regroupe la majorité des pays, caractérisés par un **signal bio faible ou négatif**. Ces marchés présentent des barrières logistiques, économiques ou réglementaires plus élevées pour une entrée à court terme du poulet biologique français. Cette différence peut expliquer pourquoi le clustering, calculé sur ****PC1, PC2 et PC3****, peut séparer certains pays qui semblaient proches dans le plan PC1 / PC2.

Indice de stabilité ARI: 1.000

Pays qui changent de cluster = 0

Variance cumulée : PC1 : 68,10%

Variance cumulée : PC2 : 83,21%

Variance cumulée : PC3 : 89,27%

Partie2 : Robustesse de la segmentation

Deux tests de sensibilité ont été conduits pour s'assurer que la segmentation résiste aux perturbations structurelles du jeu de données.

Test 1 — Retrait des 3 pays agricoles dominants

Les 3 pays les plus influents (basé sur log_production_poulet) ont été retirés du modèle. (BRA,RUS,IND)

Résultat : Aucun pays ne change de cluster (ARI ≈ 1). La structure de segmentation est intégralement préservée.

Test 2 — Retrait du point atypique (Allemagne)

L'Allemagne présente une coordonnée PC2 très élevée (profil risque sanitaire/productif hors norme), susceptible de distordre la segmentation.

Résultat : Segmentation stable (ARI ≈ 1). L'outlier n'influence pas les clusters.


✓ → La segmentation en **2 clusters est robuste** aux outliers et aux pays structurants. Les résultats sont fiables et reproductibles.

Cycle itératif après retrait des 3 pays agricoles dominants et retrait du point atypique → Confirmation de la robustesse du Modèle Kmeans testé par l'indice ARI

Partie2 : CAH : Classification Ascendante Hiérarchique

Étape 2 — Contrôler la cohérence par CAH

Le dendrogramme ci-dessous (méthode de Ward) confirme visuellement la segmentation en **2 clusters principaux**. La coupure au niveau optimal révèle deux familles de pays bien distinctes, validant les résultats obtenus par KMeans.



La ligne de coupure horizontale permet d'identifier clairement les **2 groupes stables**. Les pays du Cluster 1 se regroupent à gauche, tandis que ceux du Cluster 2 (signal premium fort) forment une branche distincte à droite.

Cycle itératif → Objectif : vérifier si les pays recommandés par le Top 5 KMeans restent dans la même famille lorsqu'on lit la segmentation avec la CAH alignée.

135 pays clustérisés confirmés

Pays qui changent de cluster = 3

1 pays du Cluster 2 à surveiller
qui nécessite une relecture
(Belgique)

2 pays du Cluster1 Kmeans qui
nécessitent une relecture marché
prioritaire (Dominique, E.A.U)

9 pays sur 10 du Top 5 par cluster
sont dans la même famille selon
KMeans et la CAH alignée

Partie2 : Comparaison KMeans vs CAH


Alignement des méthodes

9 pays sur 10 du Top 5 sont classés dans la **même famille** selon KMeans et CAH – un niveau d'accord exceptionnel qui renforce la fiabilité de la segmentation.
1 pays nécessite une relecture approfondie (ex : Belgique), dont le profil se situe à la frontière des deux clusters.

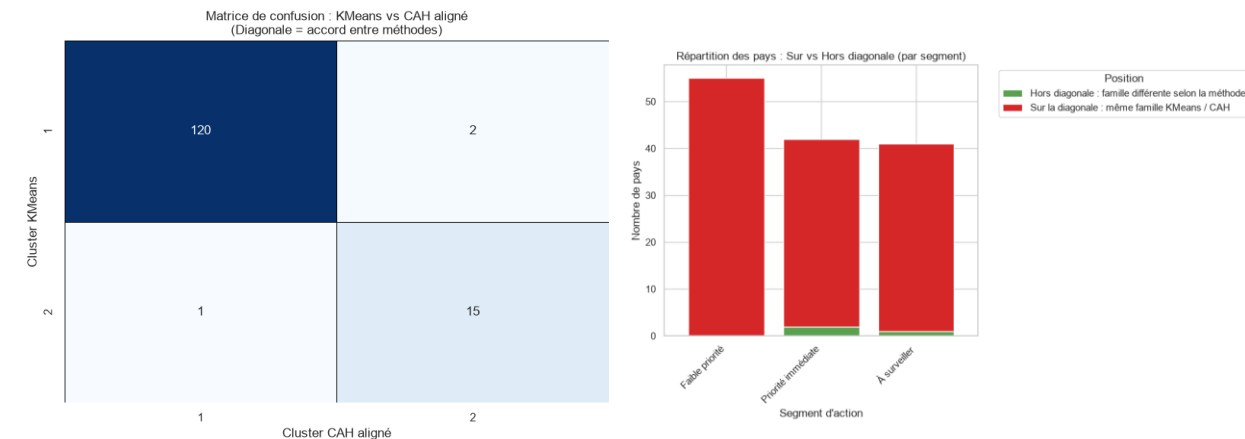
Lecture stratégique

- **KMeans** : Segmentation **opérationnelle** – affectation claire et scalable de chaque pays à un groupe.
- **CAH** : Validation **hiérarchique** – robustesse et interprétation des proximités entre pays.
- **Décision finale** : Prioriser les pays **confirmés par les deux méthodes** pour maximiser la confiance analytique.

Comparaison visuelle des pays recommandés : CAH alignée vs KMeans



Confirmation par la diagonale de la Matrice de confusion des 138 Pays par Clusters



Partie2 : Profil des deux clusters



Cluster 2 — Priorité immédiate

- **PC1 élevé** : Signal bio/import premium fort
- **Part des importations de poulet** : Élevée
- **Stabilité politique** : Bonne
- **Facilité d'affaires** : Élevée


Exemples : Suisse, Belgique, Autriche, Lettonie, Estonie



Cluster 1 — Approche prudente

- **PC1 proche de la médiane** : Signal bio/import moins marqué
- **Environnement économique** : Variable selon les pays
- **Accès au marché** : À qualifier au cas par cas

Stratégie : Veille active ou qualification progressive avant engagement commercial.



Partie2 : Top 5 des pays

Cluster 2 Marché Prioritaire

1. **Suisse (CHE)** — Score : **67.99**
2. Dominique (DMA) — Score : 58.64
3. Émirats arabes unis (ARE) — Score : 57.39
4. Belgique (BEL)
5. Autriche (AUT)

Ces pays combinent signal bio/import premium fort et environnement d'affaires favorable — cibles prioritaires pour l'export.

Cluster 1 Marché de Comparaison & sécurisation

Les pays du Cluster 2 présentent un **profil moins marqué sur PC1**, avec un signal bio/import plus modéré.

Rôle stratégique :

- Marchés de **comparaison** pour affiner le positionnement
- Options de **sécurisation commerciale** si les marchés prioritaires rencontrent des obstacles
- Pipeline d'expansion à **moyen terme**

Partie2 : Shortlist 3 & Recommandation finale

Le classement final par **score composite** croise les résultats KMeans, CAH et les indicateurs macroéconomiques pour identifier le marché prioritaire avec le plus haut niveau de confiance.

Ra ng	Pays	Score	Cluster KMeans	Cluster CAH	Accord CAH/KMeans
1	Suisse (CHE)	67.99	2	2	✓ Oui
2	Dominique (DMA)	58.64	1	1	✓ Oui
3	Émirats arabes unis (ARE)	57.39	1	1	✓ Oui

  **Pays recommandé en priorité : Suisse (CHE)** – Score composite le plus élevé (67.99), accord total KMeans/CAH, et PC1 = 10.74 (signal bio/import premium très favorable).

Partie2 : Synthèse des résultats clés

Un récapitulatif des indicateurs décisifs issus de l'analyse complète ACP + Clustering, couvrant 139 pays avec une robustesse méthodologique validée.

138

Pays (dont 135 sur la Diagonale de la matrice de confusion et 3 Hors diagonale)

11 variables actives, 0 valeur manquante — base de données nettoyée et consolidée.

89.9%

Variance expliquée

PC1 + PC2 + PC3 capturent l'essentiel de l'information du jeu de données.

0.70

Score silhouette

Valeur maximale obtenue pour k=2 — excellente séparation des clusters.

67.99

Score Suisse

Meilleur score composite toutes méthodes confondues — marché prioritaire validé.

Élément	Résultat
Nombre de clusters	2 (score de silhouette = 0.70)
Pays recommandé	Suisse (CHE) – Score : 67.99
Shortlist	Dominique (DMA), Émirats arabes unis (ARE)
Robustesse	Segmentation stable (ARI $\approx$ 1 après tests de sensibilité)

Recommandations opérationnelles

Priorité 1 — Suisse (CHE)

Action : Instruire en priorité pour l'exportation de poulets biologiques.

Justification : Meilleur score composite (67.99) + profil robuste validé par les deux méthodes + signal bio/import le plus fort du panel.

Shortlist de sécurisation

Dominique (DMA) : Marché à fort potentiel d'importation
(part_importations_poulet = 0.91)
— dépendance structurelle aux imports.

Émirats arabes unis (ARE) : Facilité d'affaires élevée (79.30) et dépendance aux importations alimentaires bien établie.

Expansion secondaire

Belgique, Autriche, Lettonie, Estonie :
Marchés à surveiller pour une extension géographique à moyen terme, une fois la Suisse consolidée.

Ces pays présentent des profils intéressants mais nécessitent une qualification approfondie avant engagement.



Argumentaire pour la Suisse (CHE)

Atouts clés

1. **Signal bio/import premium** : PC1 = **10.74** — le score le plus élevé de l'ensemble des pays analysés.
2. **Stabilité politique** : Indice 1.26, environnement institutionnel de premier plan.
3. **PIB/habitant élevé** : Fort pouvoir d'achat, propice aux produits premium.
4. **Facilité d'affaires** : **76.61/100** — cadre réglementaire favorable à l'import.
5. **Accord méthodologique** : KMeans et CAH **convergent** unanimement.

Prochaines étapes

1. **Vérifier les contraintes sanitaires** : Réglementations suisses sur l'import de poulets bio (certifications requises).
2. **Identifier les distributeurs** spécialisés bio en Suisse (Migros Bio, Coop Naturaplan...).
3. **Comparer les coûts logistiques** avec Dominique et les Émirats arabes unis.
4. **Validation terrain** : Prix de marché, intensité concurrentielle, habitudes de consommation locales.