



P6 Amélioré : Optimisation de la Gestion des Données

Bottleneck Wine Shop — Analyse Exploratoire / Data Cleaning / KPI Business / IA Assistée



Reproductible & Traçable



IA Documentée



-68% cells / -76% temps

Juillet 2026 — Amélioration du livrable P6 avec IA critique, documentation structurée et preuves détaillées pour une restitution métier plus lisible.

Contexte et Objectifs Métier

Bottleneck est une boutique de vins en ligne avec un ERP physique, confrontée à des **incohérences entre 3 sources de données** (ERP, Web, Liaison). Ces incohérences entraînent un manque de visibilité commerciale et une difficulté à prendre des décisions éclairées.

1

Réconcilier les données

Fusionner ERP, Web et Liaison pour obtenir une vue unifiée.

2

Identifier les anomalies

Détecter prix invalides, marges négatives, ruptures de stock.

3


Fournir des KPI au CODIR

CA consolidé, analyse Pareto 80%, recommandations stocks et marges.

4

Restitution métier exploitable

Notebook optimisé, dashboard KPI clair, trace avant/après documentée.



Structure du Projet

Notebook Principal

49 cellules (vs 148 initialement) — exécution en ~1 min 11 sec.

5 Modules Python

- `quality_checks.py` — 18 contrôles qualité
- `stock_cleaning.py` — correction anomalies
- `data_merging.py` — rapprochement ERP/Web
- `eda_analysis.py` — Pareto, corrélations
- `kpi_analysis.py` — CA, marges, rotation

8 Fichiers de Documentation

- Cahier des charges complet
- Veille technologique (Pandas vs GE vs Soda)
- Journal IA — 26 prompts Claude documentés
- Plan projet — backlog, kanban, planning
- Matrice des indicateurs
- Synthèse finale & recommandations
- Checklist publication GitHub
- Stratégie migration Great Expectations v19+

Output

13 graphiques Plotly + 6-8 captures portfolio

Résultats Clés — Phase I : Qualité des Données

Chargement et rapprochement de **825 (ERP) + 1 513 (Web) + 825 (Liaison)** enregistrements, avec contrôles qualité systématiques.

18

Contrôles qualité

11 OK, 4 à vérifier, 2 à documenter, 1 corrigé

7

Data Contracts

Formalisés et validés

47.2%

Taux de match ERP/Web

714 / 1 513 — anomalies à investiguer

2

Stocks négatifs

Exceptions identifiées et tracées



799 références Web sans correspondance ERP — investigation requise pour sécuriser le rapprochement.

Résultats Clés — Phase II : KPI Business

CA Total

143 680 EUR/mois (octobre 2026) — revenue consolidée 

Catalogue

689 produits avec CA — diversité confirmée 

Pareto 80%

Rang **435** — catalogue large, pas fortement concentré 

Marge Moyenne

47,32% — saine 

Stock / Rotation


2,98 mois moyenne — 92 ruptures détectées 

Anomalies

10 détectées : 3 prix invalides, 7 marges négatives


Améliorations Apportées au P6 Initial

La refonte du livrable P6 a produit des gains mesurables et documentés sur toutes les dimensions clés du projet.




Réduction des cellules

148 → 49 cellules notebook




Gain de temps

~5 min → 1 min 11 sec d'exécution



Réduction code cells

105 → 39 cellules de code



Réduction markdown

43 → 8 cellules markdown



0 erreur / warning
vs 1 majeure initialement




26 prompts IA tracés
vs 0 documentation IA



Chemins relatifs
Portabilité garantie vs chemins locaux

Méthodologie : Pourquoi Pandas ?

Choix technologique justifié par une analyse comparative rigoureuse entre trois outils de contrôle qualité.

	Pandas	Great Expectations	Soda Core
 Vitesse de mise en œuvre	 fast implementation J+30	 steep learning curve	 external dependency
 Reproductibilité	 native reproducibility	 OK reproducibility	 complex YAML config
 Dépendances	 minimal dependencies	 heavy dependencies	 heavy
 Piste d'audit	 Pandas logs audit trail	 full audit trail	 limited audit trail
 Conformité RGPD	 RGPD OK	 RGPD OK	 RGPD to verify

Court terme (J+30)

Pandas pragmatique + Data Contracts formalisés — déployé et validé.

Moyen terme

Migration planifiée vers **Great Expectations v19+** (roadmap Q1 2027).

Reproductibilité, RGPD & Traçabilité IA

✅ Reproductibilité & RGPD

- Chemins relatifs robustes → portabilité garantie
- Zéro données nominatives embarquées → conformité RGPD
- Vérification prérequis automatique (Cellule 1 du notebook)
- Timekeeper intégré pour traçabilité des performances
- 4 checkpoints internes (M00, Phase I, Phase II, Final)

🤖 Journal IA — 26 Prompts Claude

Chaque interaction IA est documentée selon la structure :

→ Objectif

Pourquoi ce prompt a été formulé

→ Résultat + Décision humaine

Ce qui a été retenu ou rejeté

→ Limitations

Contraintes appliquées, alternatives testées

Limites & Prudences Analytiques



1 mois de données (octobre 2026)

Snapshot ponctuel, pas de tendance. **Recommandation** : confirmer sur données multi-mois.



Corrélations $\neq$ Causalité

Risque de faux signaux. Utiliser comme aide à la décision, pas comme preuve.



Outliers statistiques (modèle IQR)

Valider avec l'équipe métier — certains prix premium peuvent être légitimes.



Stocks & Liaison manuels

Risque de désynchronisation. Investiguer les 799 références Web sans match ERP.

Compétences RNCP 37837 Démontrées

Ce projet couvre l'intégralité des 5 blocs de compétences du titre RNCP 37837 — Analyste de données.



BC01 — Structurer & Gérer

Rapprochement 3 sources, 18 contrôles qualité, 7 Data Contracts formalisés.



BC02 — Collecter & Analyser

Nettoyage, EDA, Pareto (80% CA sur 435 produits), corrélations.



BC03 — Visualiser & Restituer

13 graphiques Plotly, dashboard KPI CODIR, synthèse écrite.



BC04 — Piloter le Projet

8 docs, 26 prompts IA, backlog kanban, veille Pandas/GE/Soda, posture consultante.



BC05 — Statistiques

Analyse Pareto, corrélations prix/marges/stocks, validation KPI et outliers.

📄 Tous les 10 critères mission P13 Partie 1 sont documentés, tracés et accessibles via le dépôt GitHub.