



Portfolio Data Analyst — Proof Points Synthétiques

Format condensé pour recruteurs et clients : chaque projet présenté selon 5 piliers essentiels — Besoin, Données, Démarche, Résultats, Limites. De l'analyse exploratoire au Machine Learning en passant par le déploiement API.

P6 → P14

PYTHON · POWER BI · DBT · ML · FASTAPI

<https://github.com/ferialzamoun-afk>

Optimisation Boutique — Bottleneck


Besoin : Boutique multi-source (ERP, Web, Liaison) désynchronisée — créer une *single source of truth* pour ventes, stocks et prix.

Démarche

Python/Pandas → EDA → Fusion cross-source → Nettoyage Z-score → Analyses Pareto/corrélations → Export Excel.

Résultats & Limites

- Doublons détectés/corrigés ; anomalies stocks identifiées ; outliers prix flagués
- Livrable : `df_final.xlsx`
- ⚠ Snapshot statique — piste : Warehouse temps réel (dbt/Snowflake)



Dashboard Gouvernance Projets — SANITORAL

Besoin : 3 personas (DG, DR, DP) nécessitent un reporting consolidé coût/délai/avancement pour arbitrage rapide en comité de pilotage.

Données

Portefeuille IT/Marketing SANITORAL. Données internes complètes.

Démarche

Power BI Desktop → Star schema (Fact/Dim) → 3 dashboards persona-spécifiques → KPI cards (seuil alerte **15%**).

Résultats

Alertes immédiates (>15% écart) ; narration décision-first. Impact : **temps décision comité réduit**.

Limites

Référentiel phases à valider. Piste : monitoring alertes temporel automatisé.



OC vs INSEE — Data Engineering & dbt

Besoin : OpenClassrooms — comprendre la couverture géographique vs INSEE pour recruter les régions sous-représentées et cibler les groupes d'âge oubliés.

Stack technique

dbt 1.11.3 + Snowflake → Staging → Intermediate (FULL JOIN) → Marts
→ CSV export via CI/CD GitHub Actions.

KPIs clés

- Taux pénétration OC : **2,3%**
- Gap régional : Île-de-France **5,1%** vs Auvergne **1,9%**
- +4% femmes inscrites
- Livrable : CSV 633 lignes → Power BI



⚠ Limites : données OC anonymes, analyse descriptive. Pistes : prédictions régionales, tableau temps réel Streamlit.

Analyse Ventes Lapage — BI & Analytics

Besoin : Librairie Lapage — passer d'un reporting statique à un dashboard interactif pour piloter le CA, détecter les best-sellers et segmenter la clientèle.

Données


3 CSV : 1 200 clients, 500 produits, 15 000 transactions. Complètes et propres.

Démarche

Python/Pandas + Streamlit → EDA → Segmentation Pareto/RFM → Tests stats → Dashboard interactif + KPI Excel.

Résultats

Top 20% clients = **80% du CA** ; segmentation B2B/B2C ; catégories top/flop identifiées. Livrables : Dashboard Streamlit + KPI Excel.



Dashboard Eau Potable — Power BI & Langage M

Contexte ODD ONU : 2,2 milliards de personnes sans accès à l'eau potable. Enjeu : identifier les régions prioritaires et évaluer la stabilité politique vs accès WASH.



Données

5 sources (Banque Mondiale, ONU) × 150+ pays × 20 ans. Harmonisées via Python + Power Query.



Résultats

200 pays classés ; 5 clusters zones critiques ; trajectoires 2000-2024. Top 20 prioritaires (<50% accès). Dashboard Power BI 5 pages + CSV étoile 180k lignes.



Modèle descriptif. Pistes : données satellite, ML clustering validé, API temps réel.

Étude Marché Export Poulets Bio — Clustering & ACP

Besoin : "La Poule qui Chante" — identifier les marchés cibles export parmi 195 pays via clustering pour concentrer les efforts sur le top 5.

Démarche ML

Python (scikit-learn) → Feature engineering (Levenshtein) → **ACP** : 11 variables actives → 3 composantes principales (**89,9% variance**) → CAH/KMeans → Profils recommandation.

Résultats

- 3 clusters : Import-dépendant stable / Croissance volailles forte / Régulation restrictive
- 7 datasets FAO/Banque Mondiale, 16 variables PESTEL
- Couverture : 138 pays
- ⚠ Pistes : tarifs réels, validation terrain, saisonnalité

Détection Faux Billets — ML & FastAPI

Besoin BCE : Détecter les faux billets € avec une accuracy >97% pour automatiser le tri et réduire les coûts de fraude.

1400

Billets dataset

900 vrais + 500 faux, 6 mesures
géométriques

80/20

Split stratifié

Train/test avec pipeline imputation +
standardisation

3

Modèles évalués

Logistic Regression retenue (recall orienté
sécurité)

Livrable : **API REST FastAPI** (routes `/predict` et `/predict/batch`) + modèle exporté `joblib`. Pistes : extension multi-devises, logs production, active learning.



Portfolio RNCP & Stage Intermarché

P13 — Portfolio Final (RNCP-37837)

Validation compétences Data Analyst via portfolio + soutenance. 6 projets phares + 9 secondaires ; **5 blocs RNCP couverts à 100%** ; veille techno 10 sections + veille métier 5 domaines.

Stack : GitHub Pages + Markdown + templates proof points. Livrables : README synthétique, 6 proof points, soutenance.

P14 — Stage Intermarché

Piloter assortiment, disponibilité et performance opérationnelle via une *single source of truth* transactionnelle.

- Stack : Python/Pandas + Power Query + Power BI + Streamlit
- KPIs : coverage assortiment, disponibilité stock jour J, ventes
- **Reporting manuel 5h → 15min automatisé**

Vue d'Ensemble — Compétences Couvertes



Data Engineering

Python/Pandas, dbt, Snowflake, ETL, CI/CD GitHub Actions (P6, P8, P14)



BI & Visualisation

Power BI (star schema, KPI cards), Streamlit interactif, Langage M (P7, P9, P10, P14)



Machine Learning

scikit-learn, ACP/clustering, Logistic Regression, FastAPI deployment (P11, P12)



Analytics & Insights

Pareto, RFM, corrélations, segmentation, recommandations actionnables (P9, P10, P11)

☐ Portfolio complet : ferialzamoun-afk.github.io/MON-PORTFOLIO-DATA — 12 projets documentés, de l'EDA au déploiement ML.

