



Analyse des ventes d'une librairie avec Python

Certification professionnelle – Option Statistiques

Feria Zamoun | Avril 2026



Exploration des données



Analyse Commerciale



Analyse Marketing



Segmentation & recommandation

Contexte & Objectifs



Analyse exploratoire des ventes de la librairie **Lapage sur 24 mois** — compréhension de la performance commerciale et identification des leviers stratégiques actionnables.

- ❏ Objectif : transformer les données ventes en décisions business actionnables


Vision KPI / Marketing

Analyses demandées par Annabelle

Relations statistiques BtoC

Analyses demandées par Julie

Nettoyage & Préparation des données



Chaque transformation est documentée et justifiée. Résultat : dataset prêt, sans valeur manquante critique.

DONNÉES

Description des données

~687K

Transactions

~8 621

Clients

~3286

Produits référencés

3

Catégories (0,1,2)

24

Mois analysés

3 tables sources : **Transactions / Produits / Clients** — jointures sur `id_prod` puis `client_id`. Enrichissements : mois, année, âge, segment client. Dataset riche et complet pour des analyses statistiques robustes.

Diagnostic des Données

Synthèse des points clés issus des contrôles qualité et des statistiques descriptives sur les trois tables : **PRODUCTS**, **CUSTOMERS** et **TRANSACTIONS**.

Produits

- 3 286 références uniques, aucun doublon détecté.
- 3 catégories observées: 0,1 et 2
- 21 produits jamais vendus
- **PRICE** : Statistiques descriptives clés
Forte dispersion, distribution asymétrique probable
- **Présence probable d'Outliers ou de produits premium**

Clients

- 8 621 clients uniques, aucun doublon détecté.
- **GENRE** : 2 modalités —dominante : **f**
(4 490 occurrences sur 8 621)
- **Année de naissance** : De 1929 à 2004 — moyenne : **1978**.
- **Activité clients** : **21 clients** sans transaction identifiés
- **Règle** : **BtoB** si **CA total > 100 000 €**, sinon **BtoC**.

Transactions

Période 2021–2023, données prêtes pour jointures et analyses.

- **Qualité des données** : Lignes vides supprimées,
- **dates converties en datetime**.
- **Période couverte** : **2021 à 2023**.

Décision méthodologique

La suite repose sur un Dataset unifié : jointure des tables, feature engineering (segment_client, âge, mois, année, labels catégorie), et analyses par segment (BtoB/BtoC et classe d'âges).



Chiffres Clés de l'Activité Commerciale

8 600

Clients totaux

4

Clients BtoB

7,6% CA

Clients BtoB

687K

Transactions totales
dont 640 734 BtoC

8 596

Clients BtoC
Segment dominant de l'activité

92% CA

Clients BtoC

12M

CA Total

11M


CA BtoC

400 000€

Atterrissage 2023

1. Le Chiffre d'Affaires mensuel (M30J) ...

Le graphique ci-dessous illustre la comparaison des séries temporelles du CA sur la période (granularité mensuelle) pour observer les tendances de croissance et les segments porteurs .



✓ **Activité** : L'activité découpée en 3 phases semble résiliente (pas de tendance baissière structurelle).


⚠ Mais il n'y a pas de dynamique de croissance récente.

CA stabilisé.
Croissance faible voire nulle.

La moyenne mobile permet une lecture simplifiée de la dynamique, mais elle ne distingue pas les composantes structurelles et saisonnières. La décomposition de la série temporelle permet d'isoler ces effets afin d'identifier si le plateau observé relève d'un ralentissement réel ou d'un cycle naturel.

1- ...suit un cycle annuel avec saisonnalité

Le graphique ci-dessous illustre le modèle de statistiques STL qui permet de décomposer sur 24 mois la Tendence, la Saisonnalité et les Résidus



Croissance soutenue

Mi-2021 → début 2022



Légère correction

Stabilisation mi-2022



Plateau résilient

Sans décroissance structurelle

3 pics saisonniers récurrents



Août–Sept
Rentrée littéraire



Oct–Nov
Prix littéraires & événements auteurs



Décembre
Fêtes de fin d'année — pic majeur

Résidus sans anomalie → **pics saisonniers annuels confirmé**

2. La croissance du CA semble reposer sur la catégorie 1...

Le graphique ci-dessous illustre la comparaison des series temporelles du CA sur la période d'activité autour des différentes categories de produits : Catégorie 1 , 0 et 2.



Catégorie1 :

suit l'évolution du CA (même cycle general mais dynamique interne différente)





Catégorie 0:

Contrairement à la catégorie 1, profil saisonnier peu marqué ; socle de revenus plus indépendant des cycles annuels. Assure la stabilité.



Catégorie 2 : est plus volatile.


Optimiser la gestion des stocks et adosser les campagnes sur la saisonnalité.



Vigilance : La dynamique du chiffre d'affaires malgré une contribution multi-segment semble reposer sur la catégorie 1. La stratégie doit donc différencier investissement, sécurisation et optimisation selon les segments en mesurant la dépendance à la catégorie1.

3. .. Mais c'est le volume des Transactions qui pilote le CA

Ce graphique permet de mesurer l'intensité d'achat dans le temps et de vérifier si l'évolution du chiffre d'affaires est surtout portée par :
- une augmentation du volume de transactions ou de la fréquence d'achat ou du panier moyen .



Interprétation :

A ce stade, le graphique montre bien des dynamiques visuelles alignées entre le volume de transactions et l'évolution du CA mensuel, notamment pendant la phase de Plateau et de stabilisation du CA. **Confirmé statistiquement par le coefficient Pearson : (CA global vs nb transactions) : 0.6749**

Recommandation : Stratégie d'acquisition pour générer plus d'achats



4. Le nombre de produits achetés est aligné sur les transactions



Interprétation :

La dynamique visuelle semble alignée sur celle du CA

Le modèle est sain . La courbe confirme les pics de saisonnalité



Prioriser les Tops en merchandising, disponibilité et campagnes marketing ciblées.

Diagnostiquer les Flops : saisonnalité, prix, qualité de la fiche produit, cannibalisation, ou faible rotation.

Mettre en place une stratégie différenciée : **maintenir**, **relancer** ou **déréférencer** selon la contribution et la marge.




5. Le volume de clients actifs confirme ...

Transformation logarithmique indispensable pour le ciblage

Distribution brute fortement asymétrique avec valeurs extrêmes (clients BtoB).

:Queue longue très visible : La masse des clients est entre : 100 €
2 000 € Typique BtoC retail. La ligne violette semble vers ~4 200 clients soit 50% des clients font 80% du CA (PARETO).

Séparation BtoB / BtoC validée statistiquement



Interprétation :

La dynamique visuelle semble alignée sur celle du CA

Le volume de clients actifs explique une partie des variations du CA mais il ne l'explique pas tout à lui seul

6... la stratégie de segmentation BtoC versus BtoB de Lapage

La courbe de Lorenz permet de mesurer la **concentration** du chiffre d'affaires entre les clients BtoC. Elle compare la part cumulée de clients (axe X) à la part cumulée de CA (axe Y).





Gini BtoB : 0,218

BtoB est MOINS concentré (Gini 0.218) → Les 4 clients se partagent le CA de manière relativement équilibrée (≈13%, 17%, 33%, 37%).



Gini BtoC : 0,358

BtoC est PLUS concentré (Gini 0.358) → indique une concentration ****modérée à marquée**** du CA BtoC certains clients-clés dominant. Gini croissant → dépendance accrue, risque de concentration




Recommandation : segmenter la base clients (fidèles, occasionnels, gros acheteurs) pour adapter les actions CRM

1- Genre & Catégorie — Test Chi² & Insights


Pour étudier le lien entre deux variables qualitatives, comme le genre et la catégorie de livres achetés, le test du χ^2 est adapté.

Résultats visuels avant :



Sur ce graphique, on peut observer que les barres sont strictement identiques entre les genres, ce qui suggère une absence d'association entre le genre et les catégories de livres achetés en valeur absolue (Hypothèse nulle H_0 : le genre et les catégories de livres achetés sont indépendants).

Résultats visuels après :



La heatmap des résidus standardisés révèle les contributions de chaque case au χ^2 . Les cellules en rouge foncé indiquent des associations fortes, les cellules en bleu foncé des sous-représentations.

Genre & Catégories (Chi2)

Conditions

- Observations indépendantes.
- Données exprimées en effectifs (pas en pourcentages).
- Effectifs théoriques suffisants dans le tableau de contingence.

Test Chi2 **significatif**,

Chi2 = 22.669, p-value = 0.0000

<0,05 (rejet Hyp d'indépendance)

➔ le genre oriente la stratégie de ciblage par catégorie de produit acheté.

Conclusion : Les femmes achètent **significativement** plus de livres de la **catégorie 1**, tandis que les hommes surreprésentent les catégories 0 et 2.

➔ Segmenter les campagnes marketing par genre : ne pas envoyer les mêmes recommandations aux femmes et aux hommes.


➔ Adapter les mises en avant sur le site selon le profil de l'utilisateur connecté.

➔ Analyser les saisonnalités par genre pour cibler les promotions au bon moment.

2- Âge & Dépense — Test (Shapiro /Spearman) & Insights

Confirmé statistiquement par le test de Shapiro qui statue sur la relation qui est non normale → le test de Spearman est recommandé et s'avère significatif.

Résultats visuels



Âge CA total (Spearman)

Test de Shapiro : **Relation non normale** → Test Spearman

Test Spearman **significatif**, l'âge oriente la stratégie de ciblage par niveau de valeur client.

✓ Corrélation **SIGNIFICATIVE**

($p = 0.0000 < 0.05$) →


Corrélation négative de force faible → Coefficient = **-0.1838**

📌 **Conslusions et actions BI** : les jeunes clients sont des acheteurs actifs : investir sur leur fidélisation dès l'entrée dans la base.

3. Âge & Fréquence — Test (Shapiro /Spearman) & Insights

Le nuage de points permet de repérer une tendance éventuelle entre l'âge et la fréquence d'achat, mais la dispersion reste importante. La validation statistique est nécessaire pour conclure sur l'existence et la force de la relation.

Résultats visuels



Âge × Fréquence d'achat (Shapiro)

Shapiro AGE -> $W=0.9734$ $p=9.504e-54$

Shapiro FREQUENCE -> $W=0.7951$

$p=5.895e-98$ → Relation non normale

Âge × Fréquence d'achat (Spearman)

Coefficient rho : +0.1092

p-value : 5.231e-65

alpha : 0.050

Significatif : Oui

Force : faible


Direction : positive.

Conclusion et Actions BI : corrélation monotone positive Spearman de force faible entre âge et fréquence d'achat. certaines tranches d'âge achètent plus souvent que d'autres. Les seniors achètent plus fréquemment → les relancer avec des communications de réactivation (emailings "coup de cœur", nouveautés saisonnières)

4. Âge & Panier Moyen — Test (Shapiro /Spearman) & Insights

Le coefficient de corrélation de Spearman indique une relation négative significative entre l'âge et le panier moyen

Résultats visuels



Shapiro âge : Âge Panier moyen (Shapiro)

- $W=0.9734$
- $p=9.504e-54 < 0,01$
- ➔ Non normale

Shapiro PANIER:

-> $W=0.7624$ $p=1.083e-101$ ➔ Non normale


Âge Panier moyen (Spearman)

- Coefficient rho : **-0.6214**
- p-value : **0.000e+00**
- ➔ correlation significative negative forte

Conclusion et Actions BI : Il existe une relation monotone négative statistiquement significative entre l'âge et le panier moyen. Cela suggère que les clients les plus jeunes génèrent des paniers plus élevés, ce qui constitue un levier stratégique important en matière de ciblage et d'acquisition

5. Âge & Catégorie de Livres — Tests Kruskal-Wallis / ANOVA & Insights

Le boxplot compare la distribution des âges selon les catégories de livres. Le test de Kruskal-Wallis permet de vérifier s'il existe une différence significative d'âge entre au moins deux catégories. Si la p-value est inférieure à 0,05, on conclut à une différence statistiquement significative des distributions d'âge selon la catégorie.



Âge ☒ Catégorie de Livres (KW)

- Kruskal-Wallis H = 71283.5758 | p-value = 0.000e+00 → **différence significative**
- Taille d'effet (epsilon^2) = 0.1113

Âge x Catégorie de Livres (Anova)

ANOVA (indicatif) F = 39585.5108 | p-value = 0.000e+00
→ dépendance significative : Oui

Conclusion et actions BI : certaines catégories sont davantage achetées par des tranches d'âge spécifiques. La librairie peut **personnaliser ses recommandations** selon l'âge du client. La taille d'effet est **forte** ($\epsilon^2 > 0,01$) : l'effet est statistiquement présent et suffisant pour actionner une segmentation même coûteuse.

Recommandations stratégiques



Grands comptes BtoB

Account manager dédié, SLA, remises sur volume



Fidélité BtoC

Cartes fidélité, club lecteurs, newsletters ciblées



Optimisation saisonnière

Anticipation stocks, campagnes pré-pics, opérations Noël / rentrée



Marketing segmenté

Genre, âge, catégorie préférée → messages personnalisés



CONCLUSION

Apports & Perspectives

Apports statistiques

- Transformation log — distribution normalisée
- Gini $\sim 0,40$ → concentration validée quantitativement
- Tests χ^2 , Spearman, Kruskal-Wallis appliqués
- Normalité vérifiée (Shapiro-Wilk + QQ plots)

Apports business

- 3 pics saisonniers exploitables
- 2 segments clients à stratégies différenciées
- Profils (âge, genre, segment) testés pour le ciblage

Ouverture & perspectives

01

Dashboard KPI automatisé

Déploiement Streamlit

CC

Moteur de recommandation

Basé sur les profils détectés

CC

A/B tests

Campagnes segmentées pour mesurer l'impact réel



Activité résiliente, leviers identifiés, modèle prêt à itérer