



Analyse des ventes d'une librairie avec Python

Certification professionnelle – Option Statistiques

Ferial Zamoun | Avril 2026



Exploration des données



Analyse Commerciale



Analyse Marketing



Segmentation & recommandation

Contexte & Objectifs



Analyse exploratoire des ventes de la librairie **Lapage sur 24 mois** — compréhension de la performance commerciale et identification des leviers stratégiques actionnables.

- ❏ Objectif : transformer les données ventes en décisions business actionnables


Vision KPI / Marketing

Analyses demandées par Annabelle

Relations statistiques BtoC

Analyses demandées par Julie

Nettoyage & Préparation des données



Chaque transformation est documentée et justifiée. Résultat : dataset prêt, sans valeur manquante critique.



Chiffres Clés

8 600

Clients totaux

4

Clients BtoB

7,6% CA

Clients BtoB

687K

Transactions totales
dont 640 734 BtoC

8 596

Clients BtoC

Segment dominant de l'activité

92% CA

Clients BtoC

12M

CA Total

11M

CA BtoC

400 000€

Atterrissage 2023



ANALYSE COMMERCIALE

Analyse Commerciale — Dynamique du Chiffre d'Affaires

Cette analyse couvre l'évolution mensuelle du chiffre d'affaires sur 24 mois, la décomposition saisonnière, la contribution par catégorie de produits, le comportement transactionnel et la segmentation client BtoB/BtoC. L'objectif est d'identifier les leviers de croissance, les risques de concentration et les recommandations stratégiques prioritaires.



Tendances CA

Analyse temporelle et décomposition STL sur 24 mois



Catégories Produits

Contribution et volatilité par segment



Transactions & Volume

Drivers opérationnels du chiffre d'affaires




Segmentation Client

Concentration BtoB vs BtoC — courbe de Lorenz

Le CA mensuel (M30J) : un plateau résilient sans dynamique de croissance récente

Le graphique ci-dessous illustre l'évolution du chiffre d'affaires mensuel sur la période d'analyse (granularité mensuelle), complétée par une moyenne mobile à 3 mois pour lisser les fluctuations et faciliter la lecture des tendances structurelles.



✓ Activ ité Résiliente


L'activité, ne présente **aucune tendance baissière structurelle**. Le niveau de CA se maintient dans une fourchette stable, témoignant d'une base commerciale solide.

⚠ Absence de Dynamique de Croissance

La moyenne mobile révèle un **CA stabilisé** avec une croissance faible à nulle sur les derniers mois observés. La décomposition STL est nécessaire pour distinguer les effets structurels des cycles saisonniers naturels et confirmer si ce plateau traduit un ralentissement réel.

Le CA suit un cycle annuel avec une saisonnalité marquée et confirmée

Le modèle STL (Seasonal and Trend decomposition using Loess) décompose la série temporelle sur 24 mois en trois composantes indépendantes : **Tendance**, **Saisonnalité** et **Résidu**. Cette approche permet d'isoler les effets et de distinguer un ralentissement réel d'un simple cycle naturel.



Croissance soutenue

Mi-2021 → début 2022 : montée progressive de la tendance structurelle.

Légère correction

Stabilisation observée dès mi-2022, sans décroissance structurelle confirmée.

Plateau résilient

Absence de tendance baissière durable. Les résidus sont stables, sans anomalie détectée.

Août–Sept

Rentrée littéraire

Oct–Nov

Prix littéraires & événements auteurs


Décembre

Fêtes — pic majeur annuel

Conclusion : Les résidus sans anomalie confirment que les pics observés sont d'origine saisonnière récurrente — 3 pics annuels identifiés et stables.

La croissance du CA repose principalement sur la Catégorie 1

L'analyse comparée des séries temporelles par catégorie révèle des comportements très distincts entre les segments. Chaque catégorie joue un rôle stratégique différent dans la construction du chiffre d'affaires global.



✓ **Catégorie 1 — Moteur de croissance**

Suit l'évolution globale du CA avec le même cycle général, mais présente une **dynamique interne plus marquée**. Profil saisonnier aligné sur le global normalisé.

✓ **Catégorie 0 — Socle de stabilité**

Profil saisonnier peu marqué, **indépendant des cycles annuels**. Assure la récurrence et la résilience des revenus de base.


⚠ **Catégorie 2 — Segment volatile**

Amplitude plus élevée, imprévisible. Nécessite une **gestion des stocks optimisée** et des campagnes alignées sur la saisonnalité.

📌 **Vigilance stratégique :** La dépendance à la Catégorie 1 est un risque de concentration. La stratégie doit différencier investissement, sécurisation et optimisation selon les segments.

C'est le volume des transactions qui pilote le chiffre d'affaires

Cette analyse en indices base 100 permet de mesurer l'intensité d'achat dans le temps et de vérifier si l'évolution du CA est portée par une augmentation du volume de transactions, de la fréquence d'achat ou du panier moyen.



Corrélation confirmée statistiquement

Les dynamiques visuelles du volume de transactions et du CA mensuel sont **fortement alignées**, notamment pendant la phase de plateau et de stabilisation.

Coefficient de Pearson (CA global vs nb transactions) : 0,6749 — corrélation positive significative.




Recommandation stratégique

Le levier principal de croissance du CA réside dans l'**augmentation du volume d'achats**. Une stratégie d'acquisition et de réactivation clients ciblée permettrait de générer davantage de transactions et de soutenir la croissance du CA dans la durée.

Le nombre de produits achetés est aligné sur les transactions



La dynamique visuelle du nombre de produits achetés par mois est **cohérente avec celle du CA global**. La courbe confirme les pics de saisonnalité identifiés précédemment. Le modèle est sain : pas de décrochage entre volume de produits et niveau de CA.



→ Prioriser les Tops en merchandising

Assurer la disponibilité permanente et lancer des campagnes marketing ciblées sur les 10 références les plus performantes en CA.

→ Diagnostiquer les Flops




Analyser saisonnalité, politique de prix, qualité des fiches produit, cannibalisation ou faible rotation pour chaque référence sous-performante.

→ Stratégie différenciée : maintenir, relancer ou déréférencer

Arbitrer selon la contribution au CA et la marge dégagée. Ne pas maintenir une référence sans potentiel identifiable.

Le volume de clients actifs confirme la dynamique du CA sans l'expliquer entièrement

La distribution brute des dépenses clients est **fortement asymétrique** avec des valeurs extrêmes liées aux clients BtoB.
Une transformation logarithmique est indispensable pour segmenter efficacement la base et cibler les actions CRM.



Règle de Pareto

4 200 clients (50% de la base) génèrent **80% du CA**
— concentration typique d'un profil retail BtoC
avec queue longue.

Masse BtoC

La majorité des clients se situe entre **100 €**
et 2 000 € de dépenses annuelles
— profil standard retail grand public.


Séparation BtoB / BtoC

Validée **statistiquement**.

Les clients BtoB présentent des montants atypiques qui biaisent la distribution brute
et nécessitent un traitement distinct.

La segmentation BtoC vs BtoB révèle des profils de concentration distincts

La **courbe de Lorenz** mesure la concentration du chiffre d'affaires au sein de chaque segment client. Elle compare la part cumulée de clients (axe X) à la part cumulée de CA généré (axe Y). Plus la courbe s'éloigne de la diagonale d'égalité parfaite, plus la concentration est élevée.



✓ **Gini BtoB : 0,218 — Concentration faible**

Les 4 clients BtoB se partagent le CA de manière **relativement équilibrée** : ~13%, 17%, 33%, 37%. Risque de dépendance limité à court terme.

📉 **Gini BtoC : 0,358 — Concentration modérée à marquée**

Un sous-ensemble de clients-clés domine le CA BtoC. Un **Gini croissant** signalerait une dépendance accrue et un risque de concentration à surveiller activement.

📋 **Recommandation CRM** : Segmenter la base clients en trois profils — **fidèles, occasionnels, gros acheteurs** — pour adapter les actions CRM, les offres et les niveaux de service à chaque segment et réduire le risque de concentration.

Analyses Statistiques — Ciblage Marketing

Une exploration rigoureuse des relations entre variables clients — genre, âge, dépenses, fréquence — pour construire une stratégie de ciblage fondée sur des preuves statistiques.


LIBRAIRIE BTOC

TESTS χ^2 · SPEARMAN · KRUSKAL-WALLIS



Genre & Catégorie — Résidus Standardisés & Conclusions Actionnables

Heatmap des résidus standardisés du test Chi²



Les cellules en **rouge foncé** révèlent des sur-représentations significatives, les cellules en **bleu foncé** des sous-représentations. Ces résidus permettent d'identifier précisément quelles associations genre-catégorie sont statistiquement notables au-delà du hasard.

Test Chi² significatif — $\text{Chi}^2 = 22,669$ | $\text{p-value} < 0,0001$

Le seuil de 0,05 est largement dépassé : l'hypothèse d'indépendance est rejetée. Le genre oriente structurellement la stratégie de ciblage par catégorie de produit.

Femmes → Catégorie 1

Sur-représentation significative : les femmes achètent **significativement plus** de livres de catégorie 1.

Hommes → Catégories 0 & 2

Sur-représentation masculine sur les catégories 0 et 2 confirmée par les résidus.

Recommandations marketing

- **Segmenter les campagnes par genre**
Ne pas envoyer les mêmes recommandations produits aux femmes et aux hommes.
- **Personnaliser les mises en avant site**
Adapter les visuels et suggestions selon le profil de l'utilisateur connecté.
- **Analyser les saisonnalités par genre**
Cibler les promotions au bon moment selon les comportements d'achat saisonniers détectés.

Âge & Dépenses — Shapiro / Spearman

La normalité des distributions est testée via Shapiro-Wilk. Les QQ plots confirment une distribution non normale pour l'âge et le montant total. Le test de Spearman, adapté aux relations non paramétriques, est donc appliqué.

Résultats Spearman — Âge × CA Total

Coefficient ρ

-0.1838

p-value

0.0000 < 0.05

Direction

Négative


Force

Faible

Conclusion & Action BI

La corrélation est **statistiquement significative** : les jeunes clients génèrent des dépenses totales plus élevées. Ce signal faible mais fiable indique un levier prioritaire d'acquisition et de fidélisation dès l'entrée dans la base client.


- Investir sur la fidélisation des jeunes acheteurs dès leur première commande pour maximiser la valeur vie client (LTV).



Âge & Fréquence / Panier Moyen — Spearman


Deux analyses complémentaires éclairent le comportement d'achat selon l'âge : la fréquence d'achat et le panier moyen, toutes deux testées avec Spearman après confirmation de non-normalité par Shapiro-Wilk.

Âge × Fréquence d' achat



$\rho = +0.1092$ | $p = 5.231e-65$ — Corrélation positive faible mais significative. Les seniors achètent **plus fréquemment** → les relancer avec des emailings de réactivation, nouveautés saisonnières.


Âge × Panier Moy en



Corrélation négative significative — Les jeunes clients génèrent des paniers plus élevés. Levier stratégique clé pour le ciblage acquisition : prioriser les segments 18–35 ans dans les campagnes de conversion.

Âge & Catégorie de Livres — Kruskal-Wallis / ANOVA

Le boxplot compare la distribution des âges selon les catégories de livres. Le test de Kruskal-Wallis permet de vérifier l'existence d'une différence significative d'âge entre au moins deux catégories.



Résultats statistiques

Kruskal-Wallis

71 283.58 | $p = 0.000$

ANOVA (indicatif)

$F = 39\,585.51$ | $p = 0.000$

Taille d'effet ϵ^2

0.1113 — Forte

Conclusion & Action BI

Certaines catégories sont achetées par des tranches d'âge spécifiques. La taille d'effet forte ($\epsilon^2 > 0.10$) justifie une **segmentation par âge** pour personnaliser les recommandations, même à coût élevé.

Résultats clés

Segmentation validée

Segmentation clients statistiquement validée, permettant une lecture structurée du portefeuille: fidèles, occasionnels, gros acheteurs

3 pics saisonniers

Trois pics saisonniers identifiés et exploitables pour orienter les actions commerciales: segmenter par le genre, recommandations par tranches d'âge

Relation âge–panier

Corrélation significative entre âge et panier moyen ($\rho = -0,62$; $p < 0,001$).

Les jeunes dépensent plus et ont un panier plus élevé

Concentration du CA

Concentration modérée du chiffre d'affaires mesurée par un indice de Gini de 0,40.

Dépendance marqué à la catégorie 1 et suivi temporel du gini selon les segments à surveiller



Implications business

Les jeunes clients, moteurs du panier

La corrélation négative âge–panier confirme que les clients les plus jeunes génèrent les paniers les plus élevés — un segment à prioriser dans les stratégies d'acquisition et de fidélisation.

Une performance structurée par segments

La performance commerciale n'est pas homogène : elle est portée par des segments différenciés avec des comportements d'achat distincts.

Une saisonnalité anticipable

Les trois pics identifiés sont prévisibles et actionnables, offrant une fenêtre d'opportunité pour planifier les campagnes en amont.



Passer à l'action

Les analyses statistiques ont livré des signaux clairs. Il appartient désormais aux équipes métier de les traduire en décisions concrètes, mesurables et itératives.



Données

Segmentation & corrélations
validées statistiquement



Insights

Saisonnalité, jeunes clients,
concentration du CA



Actions

Ciblage, activation saisonnière, pilotage KPI